


Llm 차등보안 한국어 적용

CTO 차세대 컴퓨팅 연구소 DeAI Task 김경빈

- Presenter: 김경빈
- Topic: Ilm 차등보안(SnD) 한국어 적용
- Data and Baseline:
 - Baseline source code: <https://github.com/NusloraPrivacy/eaas-privacy>
 - 논문 : <https://arxiv.org/pdf/2310.09130>
 - Dataset : <https://github.com/e9t/nsmc> (네이버 영화 리뷰)
- Git : <https://github.com/kyoungbinkim/lg-snu-nlp>
- 가정 : 영어에 SnD 방법론이 잘 적용되었다면 한국어에서도 잘 적용될 것이다.


Petals 및 진행중인 업무 소개

- LG전자에서 출시하는 **edge device**들에서 거대 **llm**을 돌리는 것이 목표
- **Petals** : 분산 협업 추론 시스템
 - 여러 사용자의 **GPU** 자원을 연결하여 초대형 **LLM**을 소비자용 하드웨어에서 실행 가능하게 함




Petals 및 진행중인 업무 소개

- 다양하게 해결해야하는 문제가 존재
 - Confidentiality, Integrity 문제..
 - Solution : zkp, MPC, FHE, DP



SnD: split and denoise

- 차등보안의 일부로 임베딩 후 에 노이즈를 추가해서 추론요청
- **Denoise** 모듈로 출력 노이즈 제거
 - 업무중에 알고는 있었으나 모델을 학습해야하는 부담. 이번 기회로 실험 진행 및 개선



SnD: split and denoise

- 베이스라인에서 한국어를 실행 가능 하도록 학습
- Denoise 모델 구조

```
Denoise model parameters: 26,592,769
Denoise model summary:
DenoiseModel(
  (input_proj): Linear(in_features=1536, out_features=768, bias=True)
  (activation): Tanh()
  (transformer_layers): ModuleList(
    (0-5): 6 x TransformerBlock(
      (attention): MultiheadAttention(
        (out_proj): NonDynamicallyQuantizableLinear(in_features=768, out_features=768, bias=True)
      )
      (norm1): LayerNorm((768,), eps=1e-05, elementwise_affine=True)
      (norm2): LayerNorm((768,), eps=1e-05, elementwise_affine=True)
      (ff): Sequential(
        (0): Linear(in_features=768, out_features=1024, bias=True)
        (1): GELU(approximate='none')
        (2): Dropout(p=0.2, inplace=False)
        (3): Linear(in_features=1024, out_features=768, bias=True)
        (4): Dropout(p=0.2, inplace=False)
      )
    )
  )
  (pooling): AttentionPooling(
    (attention): Linear(in_features=768, out_features=1, bias=True)
    (dropout): Dropout(p=0.2, inplace=False)
    (output_proj): Linear(in_features=768, out_features=768, bias=True)
  )
  (output_proj): Linear(in_features=1536, out_features=768, bias=True)
)
```

SnD: split and denoise

- 베이스라인에서 한국어를 실행 가능 하도록 학습
- 학습결과 및 실험 결과



```
Starting denoise model training...
```

```
Epoch 1/2: 100% |████████████████████| 625/625 [03:49<00:00, 2.73it/s, loss=0.91]
```

```
Epoch 1 - Average Loss: 3.231721
```

```
Epoch 2/2: 100% |████████████████████| 625/625 [04:02<00:00, 2.57it/s, loss=2.43]Epoch 2 - Average Loss: 1.253910
```

```
Training completed!
```



SnD: split and denoise

- generate 실행 결과
 - 기본 gpt2 한국어 성능 X

예시 1

- ◆ [입력] 원본 프롬프트:
"이 영화는 정말 감동적이었어요. 배우들의 연기가 훌륭했습니다."
- ◆ [토큰화] 입력 토큰 수: 50
- ◆ [노이즈 정보]
평균: 0.001878
표준편차: 0.291171
L2 Norm: 57.0581

[노이즈 없음] Clean 임베딩으로 100 토큰 생성

생성된 텍스트:
"자여연 일열으느 아능 임마이 바리장이 고있놋 입니다. 의입이💎"


[노이즈 추가] Noisy 임베딩으로 100 토큰 생성 ($\eta=100.0$)

생성된 텍스트:
"울연여양용이 바드늘 인얏은웁욕열선윗억웁앓을. 일얏윗"

SnD: split and denoise

- 한국어 특화 gpt2를 활용해 학습 및 실험
 - 한국어 학습한 gpt2 사용 (<https://github.com/SKT-AI/KoGPT2>)

```
Starting denoise model training...
Epoch 1/2: 100%|██████████| 313/313 [03:54<00:00, 1.33it/s, loss=1.51]
Epoch 1 - Average Loss: 1.502102
Epoch 2/2: 100%|██████████| 313/313 [03:57<00:00, 1.32it/s, loss=1.43]Epoch 2 - Average Loss: 1.357616
Training completed!
```



SnD: split and denoise

- generate 실행 결과

- [입력] 원본 프롬프트:
"이 영화는 정말 감동적이었어요."

- [토큰화] 입력 토큰 수: 8
토큰: ['_이', '_영화는', '_정말', '_감동', '_적', '_이었', '_어', '_요.']

- [노이즈 정보]
평균: -0.006386
표준편차: 0.272875
L2 Norm: 21.3931

- [노이즈 없음] Clean 임베딩으로 100 토큰 생성

생성된 텍스트:
"그니까 저는 영화도 좋지만 사실 제가 좋아하는 게 뭐냐면 영화를 보면서 되게 재밌게 봤거든요? 맞아. 근데 이제 그런 거 좀 많이 보 그냥 보는 것만으로도 굉장히 즐거운데 음음 그리고 또 다른 어떤 느낌일 수도 있고 네네. 이런 것들이 있더라고요 그래서 나는 진짜로 그렇게 좋아하는데 막상 보니까 약간 조금"

- [노이즈 추가] Noisy 임베딩으로 100 토큰 생성 ($\eta=100.0$)

생성된 텍스트:
"는 그~ 저도 모르게 눈물이 나더라고요? 네. 그래서 제가 이제 영화를 보러 갔는데 어머님께서 너무너무 좋아하셨거든요. 네. 근데 영화 보면서 아까 말씀드린 것처럼 우리 가족들이 다 같이 모여서 이렇게 얘기하고 또 서로에 대해서 이야기하면서 이런 이야기를 그런 의미에서 이번에도 역시나 뭔가 좀 특별한 게 있었"

SnD: split and denoise

- generate 실행 결과

```
• [입력] 원본 프롬프트:
"인공지능 기술은 우리 삶을"

• [토큰화] 입력 토큰 수: 6
토큰: ['_인공', '지', '능', '_기술은', '_우리', '_삶을']

• [노이즈 정보]
평균: 0.001279
표준편차: 0.273231
L2 Norm: 18.5457

● [노이즈 없음] Clean 임베딩으로 100 토큰 생성

생성된 텍스트:
"더욱 풍요롭게 만들어 줄 것이다.
이러한 기술들은 인간의 삶에 필요한 모든 것을 가능하게 한다.
그렇다면 우리는 어떻게 해야 할까?
우리가 살아가면서 가장 중요한 것은 무엇일까?
바로 '삶의 질'이다.
우리는 매일매일 새로운 일을 하고 있다.
하지만 그 일에 대한 만족도는 매우 낮다.
특히, 일터에서 일하는 사람들은 대부분 자신의 업무 능력을 과소평가하고 있는 경우가 많다.
또한, 이러한 부정적인 평가에 대해 불만을 가지고 있을 수도 있고, 반대로 자신이 원하는 것이 무엇인지 잘 모르고 있다는 사람도 적지 않다.
그러나 우리가 살아가는 동안 많은"
```

```
● [노이즈 추가] Noisy 임베딩으로 100 토큰 생성 (η=100.0)

생성된 텍스트:
"더 나은 삶으로 이끄는 데 큰 역할을 할 것이다.
이러한 기술들은 인간의 삶에 대한 통찰력을 높여준다.
그렇다면 우리는 어떻게 해야 하는가?
우리가 알고 있는 것처럼 인간은 누구나 자신의 능력을 최대한 발휘할 수 있다.
하지만 그 능력은 한계가 있을 수밖에 없다.
인간은 자신이 가진 재능과 한계를 잘 활용하지 못한다.
그래서 사람들은 자기 자신을 개발하기 위해 노력한다.
그러나 이러한 노력은 결국 실패를 불러온다.
자신의 재능을 제대로 발휘하려면 어떤 노력을 기울여야 하는가.
우리는 스스로에게 필요한 것을 찾아내고 그것을 통해"
```

analysis


항목	GPT-2	KoGPT2
토큰나이저	영어 BPE	한국어 Character BPE
Vocab Size	50,257	51,200
학습 데이터	영어 WebText 40GB	한국어 텍스트 40GB+
한국어 토큰화	바이트 단위 분해 (비효율)	형태소/음절 단위 (효율)
한국어 성능	❌ 거의 불가	✅ 우수

analysis


- Word2Vec

- 의미상 비슷하면 거리가 가까울 것이다.
- 단순히 노이즈를 추가하는 것이 아니라 추론이 잘 되도록 벡터 집단을 만들어 추론

Workflow of RANTEXT



On the left: the process of computing a random adjacency list for the token "years".



On the right: a toy example of perturbing a raw document to obtain a perturbed version.